

# **Les Expressions Régulières**

**S. MAZOUZ & B. LAICHI**

**FEI-USTHB**

**Département Informatique**

**2019-2020**

**campusvirtuel.usthb.dz**

# Plan

- 1) Expressions Régulières  
(Définitions, Exemples et Propriétés).
- 2) Expressions régulières et Automates d'états finis.
- 3) Applications des expressions régulières.
- 4) Caractérisation des langages réguliers.

# Expressions Régulières

## Introduction :

Les langages **réguliers** sont les langages :

- **générés** par des grammaires de type 3 appelées grammaires régulières.
- **reconnus** par des automates d'états finis. On dit aussi que c'est des langages reconnaissables.

Les mots de tels langages possèdent une forme particulière et peuvent être dénotés par des **expressions régulières (ou expressions rationnelles)**.

Une **expression régulière** est une suite de caractères, appelée motif (ou pattern en anglais), qui **décrit** ou **dénote** un ensemble de mots.

# Expressions Régulières

**Définition :** Les expressions régulières sur **un alphabet  $X$**  sont définies d'une manière inductive comme suit :

**Cas de base :**

- $\emptyset$  est une expression régulière  
qui **décrit le langage vide**
- $\varepsilon$  est une expression régulière  
qui **décrit le langage  $\{\varepsilon\}$**
- $a$  est une expression régulière  $\forall a \in X$   
qui **décrit le langage  $\{a\}$**

# Expressions Régulières

## Définition (suite)

### Cas d'induction :

Si  $r$  et  $s$  sont deux expressions régulières sur  $X$  décrivant respectivement les langages  $R$  et  $S$  alors :

- $r+s$  est une expression régulière  
qui décrit le langage  $R \cup S$
- $r.s$  est une expression régulière  
qui décrit le langage  $R.S$
- $r^*$  est une expression régulière  
qui décrit le langage  $R^*$
- $(r)$  est une expression régulière  
qui décrit le langage  $(R)$

# Expressions Régulières

## Exemples :

- $E_1 = a+b$       dénote le langage  $\{a\} \cup \{b\} = \{a, b\}$
- $E_2 = a.b$       dénote le langage  $\{a\} . \{b\} = \{ab\}$
- $E_3 = E_1.E_2 = (a+b).a.b$       dénote le langage  $\{a, b\} . \{ab\} = \{aab, bab\}$
- $E_4 = a^*$       dénote le langage  $\{a\}^* = \{a^n / n \geq 0\}$

**Remarque :** Le symbole de concaténation peut être omis. Par exemple, on peut écrire  $ab$  au lieu de  $a.b$

# Expressions Régulières

## Exemples :

- $E_5 = a^* + b^*$       dénote le langage  $\{a\}^* \cup \{b\}^*$
- $E_6 = (a+b)^*$       dénote le langage  $\{a, b\}^*$   
qui correspond à tous les mots sur  $\{a, b\}$
- $E_7 = (a+b)^*aab$       dénote tous les mots de  $\{a, b\}^*$   
se terminant par **aab**
- $E_8 = (a+b)^*aba(a+b)^*$       dénote tous les mots de  $\{a, b\}^*$   
contenant le facteur **aba**.

# Expressions Régulières

Définition (**Equivalence**)

Deux expressions régulières  $E_1$  et  $E_2$  sont **équivalentes**, notées  $E_1 \equiv E_2$ , si et seulement si elles **dénotent le même langage**.

**Exemple** : On veut décrire le langage  $\{a, b\}^+$ .

$E_1 = (a+b)(a+b)^*$  /\* une lettre a ou b suivie d'une séquence aléatoire de a et b \*/

$E_2 = (a+b)^*(a+b)$  /\* une suite aléatoire de a et b suivie par une lettre a ou b \*/

Dans les deux cas, le langage dénoté est une suite aléatoire de a et b avec au minimum une lettre : a ou b. Donc,  $E_1 \equiv E_2$ .

**Remarque** : Pour simplifier les expressions, nous supposons que l'étoile '\*' est plus prioritaire que la concaténation '.' qui est plus prioritaire que l'addition '+' : **étoile > concaténation > addition** :  $a+b.a^*$



# Expressions Régulières

## Propriétés sur les expressions régulières :

Soient **p** et **q** deux expressions régulières dénotant deux langages **P** et **Q**

1. **Commutativité** :  $p+q \equiv q+p$
2. **Associativité** :  $p+(q+r) \equiv (p+q)+r$   $p(qr) \equiv (pq)r$
3. **Distribution** :  $(p+q)r \equiv pr + qr$   $p(q+r) \equiv pq + pr$
4. **Élément neutre** :  $p.\varepsilon \equiv \varepsilon.p \equiv p$   $p+\emptyset \equiv \emptyset+p \equiv p$
5. **Élément absorbant** :  $p.\emptyset \equiv \emptyset.p \equiv \emptyset$
6.  $\emptyset^* \equiv \varepsilon$
7.  $(p^*)^* \equiv p^*$
8.  $(p^*+q^*)^* \equiv (p^*.q^*)^* \equiv (p+q)^*$
9.  $p.p^* \equiv p^*.p$
10.  $p^* \equiv (p+\varepsilon)^*$

**Remarque** :  $pq \neq qp$  (la concatenation n'est pas commutative)

# Expressions Régulières

## Exemple :

Soient les expressions régulières suivantes :

$$E_1=(a^*b^*)^* \quad E_2=(a^*+b^*)^* \quad \text{et} \quad E_3=(a+b)^*$$

Or, on a la propriété :  $(p^*+q^*)^* \equiv (p^*.q^*)^* \equiv (p+q)^*$

Ces trois expressions sont équivalentes. En effet, elles dénotent le même langage  $\{a, b\}^*$ .

**Définition** : Un langage  $L$  sur un alphabet  $X$  est un **langage rationnel** si et seulement s'il existe une expression régulière  $E$  sur l'alphabet  $X$  qui le dénote.

On note **Rat**( $X^*$ ) la famille des langages rationnels sur  $X$ .

# Expressions Régulières et Automates d'Etats Finis

## Théorème de Kleene :

L'ensemble **des langages rationnels** (décrits par des expressions régulières) sur un alphabet  $X$  est exactement l'ensemble **des langages sur  $X$  reconnaissables** par automate d'états finis.

Nous avons  $\text{Rat}(X^*) = \text{Rec}(X^*)$  où

$\text{Rat}(X^*)$  est la famille des **langages rationnels** sur  $X$  (tout langage décrit par une expression régulière est un langage rationnel).

$\text{Rec}(X^*)$  est la famille des **langages reconnaissables** sur  $X$  (tout langage reconnu par un automate d'états finis est un langage reconnaissable).

# Expressions Régulières et Automates d'Etats Finis

## Proposition :

A toute **expression régulière  $E$** , il existe un **automate d'états fini  $A(E)$** , **reconnaissant** le langage dénoté par  $E$ .

Les méthodes les plus répandues pour la construction d'un automate à partir d'une expression régulière sont :

- La méthode de Thompson
- La méthode de Brzozowski (méthode des dérivées).
- .
- .


# Expressions Régulières et Automates d'Etats Finis

## Méthode de Thompson :

L'algorithme consiste à construire l'automate petit à petit (étape par étape), en utilisant des constructions standard pour l'union, la concaténation et l'étoile en se basant sur la structure de l'expression régulière.


- **L'expression  $\varepsilon$**

on lui associe l'automate :




- **L'expression  $a$**

on lui associe l'automate :



- **L'expression  $\emptyset$**

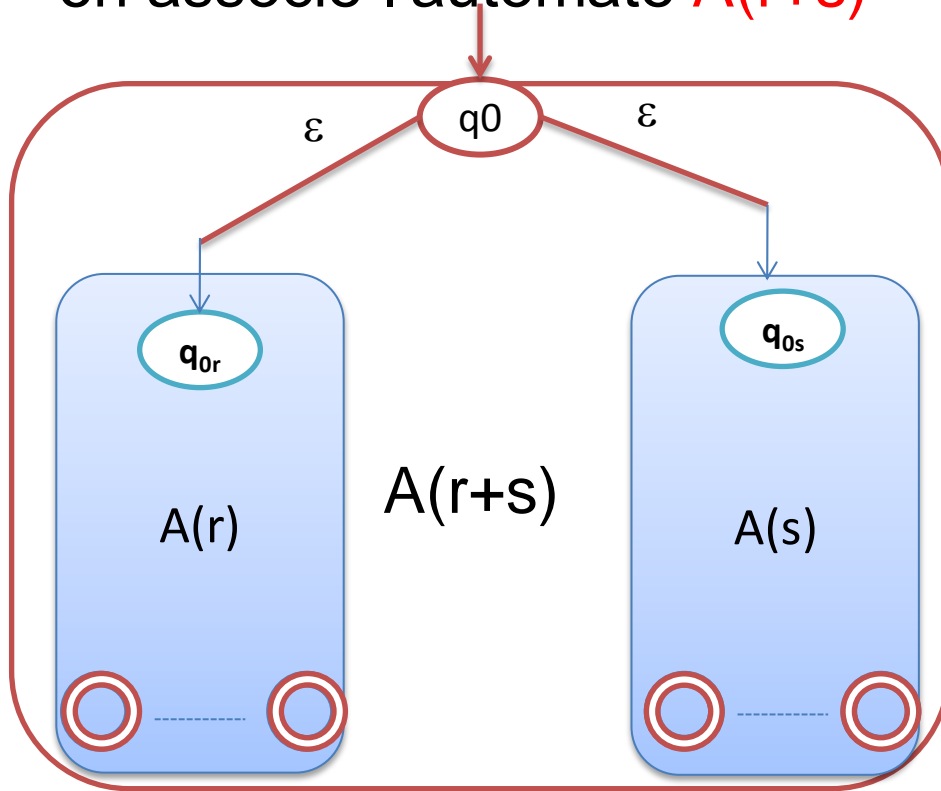
on lui associe l'automate :



**Remarque :** Un automate sans état final ne reconnaît aucun mot.

# Expressions Régulières et Automates d'Etats Finis

Pour l'expression  **$r+s$** ,  
on associe l'automate  **$A(r+s)$**



**Données :**

$$A(r) = (X_r, Q_r, q_{0r}, \delta_r, F_r)$$

$$A(s) = (X_s, Q_s, q_{0s}, \delta_s, F_s)$$

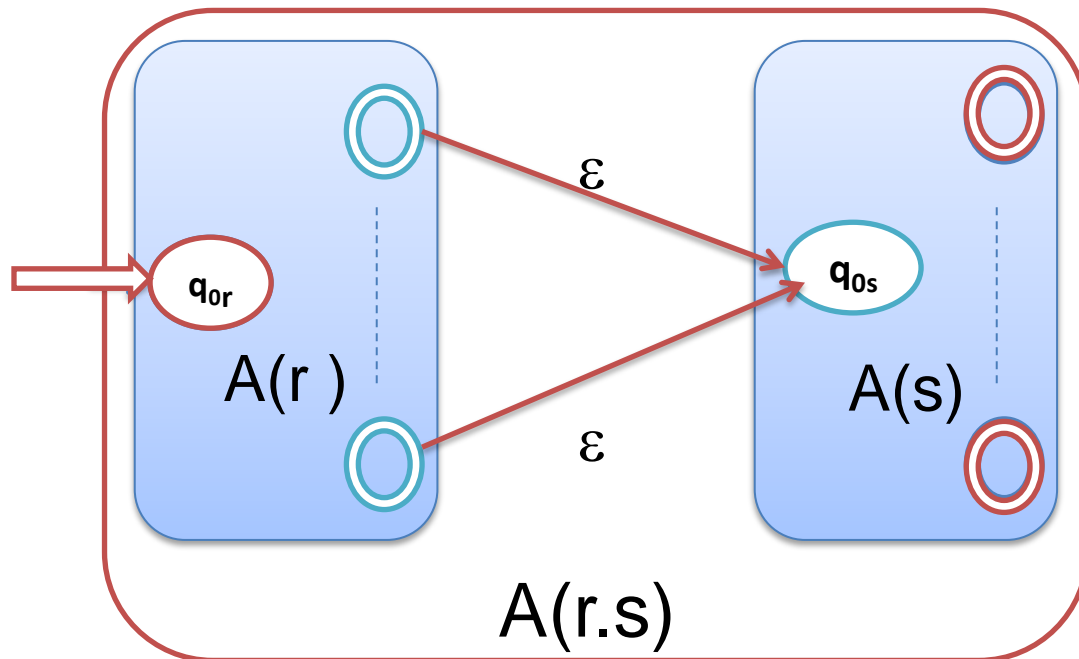
Formellement, on a :

**$A(r+s) = (X, Q, q_0, \delta, F)$  où :**

- $X = X_r \cup X_s$
- $Q = Q_r \cup Q_s \cup \{q_0\}$
- $q_0 / q_0 \notin (Q_r \cup Q_s)$
- $\delta = \delta_r + \delta_s + \delta(q_0, \epsilon) = \{q_{0r}, q_{0s}\}$
- $F = F_r \cup F_s$

# Expression Régulière et Automate d'Etats Finis

- Pour l'expression **r.s**,  
on associe l'automate **A(r.s)**



**Données :**

$$A(r) = (X_r, Q_r, q_{0r}, \delta_r, F_r)$$

$$A(s) = (X_s, Q_s, q_{0s}, \delta_s, F_s)$$

Formellement, on a :

$$A(r.s) = (X, Q, q_0, \delta, F) \text{ où}$$

$$- X = X_r \cup X_s$$

$$- Q = Q_r \cup Q_s$$

$$- q_0 = q_{0r}$$


$$- \delta = \delta_r + \delta_s +$$

$$\delta(q, \epsilon) = q_{0s} \quad \forall q \in F_r$$

$$- F = F_s$$

# Expression Régulière et Automate d'Etats Finis

- Pour l'expression  $r^*$ ,  
on associe l'automate  $A(r^*)$



Donnée :

$$A(r) = (X_r, Q_r, q_{0r}, \delta_r, Fr)$$

Formellement, on a :

$$A(r^*) = (X, Q, q_0, \delta, F) \text{ où}$$

- $X = X_r$
- $Q = Q_r \cup \{q_0\}$
- $q_0 / q_0 \notin Q_r$
- $\delta = \delta_r + \delta(q_0, \epsilon) = q_{0r} +$   
 $q_{0r} \in \delta(q, \epsilon) \quad \forall q \in Fr$
- $F = Fr \cup \{q_0\}$



# Expressions Régulières et Automates d'Etats Finis

## Proposition :


A tout automate d'états fini **A**, il lui correspond une **expression régulière qui le dénote**.

Le langage reconnu par cet automate est dénoté par l'expression régulière : **ba\*bb\***

Pour l'obtention d'une expression régulière à partir d'un automate d'états finis, on peut citer les méthodes suivantes :

- La méthode d'élimination ou méthode de Brzozowski et McCluskey
- La méthode par résolution d'équations

## Exemple :



# Applications des Expressions Régulières

Les expressions régulières ont de nombreuses utilités en informatique, elles servent principalement pour réaliser :

- 1) **des contrôles** : vérifier qu'une donnée entrée par un utilisateur a bien le format souhaité.
- 2) **des substitutions** : remplacer un motif par une chaîne de caractères précise ; par exemple, remplacer les majuscules par des minuscules.
- 3) **des filtres** : ne conserver que certaines lignes d'un fichier texte.
- 4) **des découpages** : récupérer une partie d'une chaîne de caractères par exemple une date placée dans une chaîne de caractères.

# CARACTÉRISATION DES LANGAGES RÉGULIERS

Les langages réguliers peuvent être **caractérisés** de 3 façons, en utilisant :

- 1) Les grammaires régulières.
- 2) Les automates d'états finis.  
(déterministes, non-déterministes ou généralisés).
- 3) Les expressions régulières.

## Remarque :

Pour démontrer qu'un langage est régulier il faut lui trouver : une **grammaire régulière** qui le génère, un **automate d'état finis** qui le reconnaît ou une **expression régulière** qui le dénote.

# CARACTÉRISATION DES LANGAGES RÉGULIERS

**Exemple :** Montrer que le langage

$L = \{w \in \{a, b\}^* / w \text{ commence et se termine par la même lettre}\}$  est régulier en utilisant les 3 méthodes.

1) L est dénoté par l'expression régulière :  $a(a+b)^*a + b(a+b)^*b$

2) L est généré par la grammaire régulière  $G=(T, N, S, P)$  avec

$T=\{a, b\}$ ,  $N=\{S, A, B\}$ , et P est défini par :

$S \rightarrow aA / bB / a / b$

$A \rightarrow aA / bA / a$

$B \rightarrow aB / bB / b$

3) L est reconnu par l'automate d'états fini :

