

Notions Fondamentales de la Théorie des Langages

MAZOUZ Samia & LAICHI Boualem

blaichi@usthb.dz

USTHB – Faculté d'Informatique
2021/2022

ALPHABET

Définition (Alphabet)

Un alphabet X est **un ensemble fini et non vide**.

Les éléments de cet ensemble sont appelés **des lettres** ou **symboles**.

Exemples :

- Alphabet binaire $X = \{0, 1\}$
- Alphabet décimal $X = \{0, 1, \dots, 9\}$
- Alphabet des gènes (ADN) $X = \{A, T, C, G\}$
- Alphabet des expressions arithmétiques $X = \{+, -, *, \div, (,), 0, 1, \dots, 9\}$.
- Alphabet latin (Anglais, ...) $X = \{a, b, c, \dots, z\}$

MOTS

Définition (Mot)

Un mot sur un alphabet X est une **suite (combinaison)** finie, éventuellement vide, d'éléments de X .

Exemples :

Alphabet	Mots
$\{0,1\}$	010 ,10 ,000 ,10011001, 111111, 0, 1
$\{A, C, G, T\}$	ATTGCT, TTTGTACGT, GTTTCA, A, G
$\{+, -, *, \div, (,), 0, \dots, 9\}$	5+3, 7***, +***))))), ((4+8) \div 2), 0, 1

MOTS

Notations :

- ❑ Le mot vide (suite vide d'éléments) est noté ε .
- ❑ L'ensemble des mots formés à partir d'un alphabet X est noté X^* .

Exemple : Si $X=\{a\}$ alors X^* est défini comme suit :
 $X^*=\{\varepsilon , a, aa, aaa, aaaa, \dots\}$

- ❑ X^+ est l'ensemble des **mots non vides**.

On a $X^*=X^+ \cup \{\varepsilon\}$.

Remarque : Les ensembles X^* et X^+ sont infinis.

OPÉRATIONS SUR LES MOTS

1) Concaténation

Définition : Soient w_1 et w_2 deux mots de X^* . On définit la concaténation comme la juxtaposition de w_1 et w_2 et on la note **$w_1.w_2$** (ou w_1w_2).

Ainsi, **si** $w_1 = a_1 \dots a_n$ et $w_2 = (b_1 \dots b_m)$

alors $w_1.w_2 = a_1 \dots a_n b_1 \dots b_m$

Remarques :

- $\varepsilon.w = w.\varepsilon = w$ (ε est :
l'élément **neutre** de la concaténation)
- La concaténation n'est pas commutative ($w_1w_2 \neq w_2w_1$)
- La concaténation est associative $(w_1w_2)w_3 = w_1(w_2w_3)$

OPÉRATIONS SUR LES MOTS

2) Longueur

Définition : On appelle longueur d'un mot w sur un alphabet X la somme des occurrences des différents symboles le constituant.

Elle est notée $lg(w)$ (ou $|w|$).

Formellement :

- $lg(\varepsilon)=0$
- $lg(a)=1 \quad \forall a \in X$
- $lg(a.w) = 1+lg(w), \quad \forall a \in X, \forall w \in X^*$

Exemples : $lg(ab)=2$ $lg(aba)=3$ $lg(abb)=3$

Notation : $|w|_a$ désigne le nombre de a dans le mot w . $|aba|_a = 2$

Remarque :

La fonction longueur est une application de X^* vers \mathbb{N} .

OPÉRATIONS SUR LES MOTS

3) Miroir

Définition: On appelle mot miroir d'un mot w , noté **Mir(w)** ou **w^R** le mot obtenu en inversant les symboles de w .

Ainsi **si** $w = a_1 \dots a_n$ **alors** $\text{Mir}(w) = a_n \dots a_1$.

Formellement :

- $\text{Mir}(\varepsilon) = \varepsilon$
- $\text{Mir}(a) = a \quad \forall a \in X$
- $\text{Mir}(a.w) = \text{Mir}(w).a \quad \forall a \in X, \quad \forall w \in X^*$

Exemples : Le miroir du mot **abbaa** est **aabba**.

Le miroir du **aba** est le **mot lui-même** (mot palindrome)

Remarque : **$(w^R)^R = w$**

OPÉRATIONS SUR LES MOTS

4) Puissance

Définition : La puissance d'un mot w est définie par récurrence de la manière suivante :

- $w^0 = \varepsilon$
- $w^{n+1} = w^n.w \quad \forall n \geq 1$

Exemple :

Les puissances du mot **abb** sont :

$\{\varepsilon, \text{abb}, \text{abbabb}, \text{abbabbabb}, \dots\}$

OPÉRATIONS SUR LES MOTS

5) Factorisation

Définition : Soient v et w deux mots de X^* .

- v est **facteur ou sousmot** du mot w si et seulement s'il existe deux mots u_1, u_2 appartenant à X^* tel que : $w = u_1.v.u_2$
- Le mot v est **facteur propre** du mot w si $u_1 \neq \varepsilon$ et $u_2 \neq \varepsilon$.
- Le mot v est **facteur gauche (ou préfixe)** de w si $u_1 = \varepsilon$.
- Le mot v est **facteur droit (ou suffixe)** de w si $u_2 = \varepsilon$

Exemples : Soit le mot $w = aabbba$, nous avons :

- Le mot $v_1 = abb$ est **facteur** de w , c'est un facteur propre ($aabbba$)
- Le mot $v_2 = aab$ est **facteur gauche** de w ($aabbba$)
- Le mot $v_3 = ba$ est **facteur droit** de w ($aabbba$)

LANGAGE

Définition : Soit X un alphabet. On appelle langage formel défini sur X tout sous-ensemble de X^* .

Exemples :

- ❑ L_1 = l'ensemble des mots de $\{a, b\}^*$ qui commencent par a
 $= \{a, aa, ab, aaa, aab, aba, abb, \dots\}$
 $= \{aw / w \in \{a, b\}^*\}$
- ❑ L_2 = l'ensemble des mots de $\{a, b\}^*$ de longueur strictement inférieure à 3
 $= \{\varepsilon, a, b, aa, ab, ba, bb\}$

Remarque : L_1 est un langage infini et L_2 est un langage fini.

LANGAGE

- ❑ Un langage **vide** est un langage qui ne contient aucun mot. Il est noté \emptyset .
- ❑ Un langage **fini** est un langage qui **contient un nombre fini de mots**. Dans l'exemple précédent L_2 est fini. Un langage fini peut être décrit par l'énumération des mots qui le composent.
- ❑ Un langage **infini** est un langage qui contient une infinité de mots. Dans l'exemple précédent L_1 est infini. De façon générale, un langage infini peut être décrit par :
 - 1) application d'opérations à des langages plus simples,
 - 2) un ensemble de règles appelées grammaires.
- ❑ Un langage est dit propre s'il ne contient pas le mot vide.
- ❑ Le langage \emptyset est **différent** du langage $\{\epsilon\}$

OPÉRATIONS SUR LES LANGAGES

Les langages étant des ensembles, on peut effectuer sur eux les opérations définies sur les ensembles :

- Union : $L_1 \cup L_2 = \{w / w \in L_1 \text{ ou } w \in L_2\}$
- Intersection : $L_1 \cap L_2 = \{w / w \in L_1 \text{ et } w \in L_2\}$
- Complément : $\overline{L} = \{w / w \in X^* \text{ et } w \notin L\}$
- Différence : $L_1 - L_2 = \{w / w \in L_1 \text{ et } w \notin L_2\}$
- Produit : $L_1 \times L_2 = \{(w_1, w_2) / w_1 \in L_1 \text{ et } w_2 \in L_2\}$

OPÉRATIONS SUR LES LANGAGES

De plus, les opérations définies sur les mots peuvent être étendues aussi aux langages.

Soient deux langages L_1 et L_2 respectivement définis sur les alphabets X_1 et X_2 et soit L un langage défini sur l'alphabet X .

o La concaténation de langages

$$L_1.L_2 = \{w_1.w_2 \mid w_1 \in L_1 \text{ et } w_2 \in L_2\}$$

Exemple : Si $L_1 = \{a, ba\}$ et $L_2 = \{b, bb, ab\}$ alors

$$L_1.L_2 = \{ab, abb, aab, bab, babb, baab\}$$

Remarques :

$$\{\varepsilon\}.L = L.\{\varepsilon\} = L$$

$$\emptyset.L = L.\emptyset = \emptyset$$

OPÉRATIONS SUR LES LANGAGES

- **Langage miroir** $L^R = \{w^R / w \in L\}$
- **Puissance concaténative** $L^0 = \{\varepsilon\}$ et $L^{n+1} = L^n.L$
- **Fermeture itérative ou Etoile** $L^* = L^0 \cup L^1 \cup L^2 \cup \dots \cup L^k \cup \dots$
 $= \bigcup_{i \geq 0} L^i$
- **L'étoile propre (ou ε libre)** $L^+ = \bigcup_{i \geq 1} L^i$

Remarques : si $\varepsilon \in L$ alors $\varepsilon \in L^*$ et $\varepsilon \in L^+$
si $\varepsilon \notin L$ alors $\varepsilon \in L^*$ et $\varepsilon \notin L^+$

GRAMMAIRE

Un langage peut être décrit comme étant un ensemble de mots satisfaisant un certain nombre de règles...

...appelées **grammaire**.

Définition (Grammaire)

Une grammaire (ou système de substitution) est un quadruplet

$G=(T, N, S, P)$ où :

- T est un **ensemble non vide de terminaux** (l'alphabet sur lequel est défini le langage).
Les symboles de T sont désignés par les lettres minuscules de l'alphabet latin (**a, b, c,...**).
- N est un **ensemble de non-terminaux** tel que $T \cap N = \emptyset$, ce sont des symboles intermédiaires pour produire de nouveaux objets (c'est les symboles qu'il faut encore définir).
Ils sont désignés par les lettres majuscules de l'alphabet latin (**A, B, C, ...**).
- $S \in N$ est appelé **axiome**.

GRAMMAIRE

Définition (Grammaire) Suite

□ P est un **ensemble de règles de productions ou de réécritures**.

Chaque règle est de la forme $\alpha \rightarrow \beta$

où $\alpha \in (T \cup N)^* N (T \cup N)^*$ et $\beta \in (T \cup N)^*$

Remarque : α et β sont des combinaisons entre terminaux et non-terminaux. De plus, α contient au moins un non-terminal.

Une règle de production $\alpha \rightarrow \beta$ signifie que :
la séquence de symboles α peut **être remplacée** par la séquence de symboles β

○ α est appelé membre gauche et β membre droit.

GRAMMAIRE

Exemple $G = (T, N, S, P)$

- $T = \{a\}$
- $N = \{S\}$
- $P = \{S \rightarrow aS, S \rightarrow a\}$

Intuitivement, cette grammaire permet de **générer** les mots :

$S \rightarrow a$

$S \rightarrow aS \rightarrow aa$

$S \rightarrow aS \rightarrow aaS \rightarrow aaa$

$S \rightarrow aS \rightarrow aaS \rightarrow \dots\dots$

Donc les mots : a, a^2, a^3, \dots ainsi le langage **généré** (ou **engendré**)
par la grammaire G est : $\{a^n / n \geq 1\}$

GRAMMAIRE

Notations :

Plusieurs règles **ayant même membre gauche** :

- Seront regroupées en écrivant une seule fois le membre gauche
- A droite du symbole \rightarrow les différents membres droits séparés par /.

Exemple : Les trois règles suivantes ont le même membre gauche

$$A \rightarrow Ba$$

$$A \rightarrow bA$$

$$A \rightarrow aA$$

On notera les 3 règles comme suit : $A \rightarrow Ba / bA / aA$

Remarque : Le symbole / signifie un choix qui n'induit **aucun sens de priorité**.

GRAMMAIRE

Définition (Dérivation directe)

Soit $G=(T, N, S, P)$ une grammaire.

Soient $w_1 \in (T \cup N)^* N (T \cup N)^*$ et $w_2 \in (T \cup N)^*$.

w_1 dérive (ou produit) directement w_2

(ou w_2 dérive directement à partir de w_1) si et seulement si :

il existe une production $\alpha \rightarrow \beta$ dans P telle que :

$$w_1 = u\alpha v \quad \text{et} \quad w_2 = u\beta v \quad (\alpha \text{ est un facteur de } w_1)$$

En d'autres termes : $u\alpha v \rightarrow u\beta v$

(α est remplacé par β dans w_1) avec $u, v \in (T \cup N)^*$.

On écrit alors **$w_1 \Rightarrow^{(1)} w_2$** ou simplement **$w_1 \Rightarrow w_2$**

GRAMMAIRE

Exemples :

Soit $G = (\{0, 1\}, \{S\}, S, \{S \rightarrow 0S1/01\})$

- S dérive directement 0S1 :

$S \Rightarrow^{(1)} 0S1$ (Règle $S \rightarrow 0S1$)

- 0S1 dérive directement 0011 :

$0S1 \Rightarrow^{(1)} 0011$ (Règle $S \rightarrow 01$)

- 0S1 dérive directement 00S11 :

$0S1 \Rightarrow^{(1)} 00S11$ (Règle $S \rightarrow 0S1$)

GRAMMAIRE

Définition (Dérivation indirecte)

Soit $G=(T, N, S, P)$ une grammaire. Soient $w_1 \in (T \cup N)^* N (T \cup N)^*$ et $w_2 \in (T \cup N)^*$. On dit que w_1 **dérive (ou produit) indirectement** w_2

(ou w_2 dérive indirectement à partir de w_1) si et seulement si :

w_2 peut être obtenu par **une succession de zéro, une ou plusieurs** dérivations directes à partir de w_1 . On écrit $w_1 \Rightarrow^* w_2$.

Remarques :

- Dans le cas d'une dérivation de longueur zéro, aucune règle de la grammaire n'est utilisée. Donc, on a $w_2 = w_1$.
- On peut indiquer la longueur n de la dérivation (nombre de dérivations directes) comme suit : $w_1 \Rightarrow^{(n)} w_2$ **exp** : $w_1 \Rightarrow^{(3)} w_2$

GRAMMAIRE

Exemples: En considérant la grammaire précédente

$G = (\{0,1\}, \{S\}, S, \{S \rightarrow 0S1/01\})$ on a :

- $S \Rightarrow^{(1)} 0S1$ et $0S1 \Rightarrow^{(1)} 0011$
donc $S \Rightarrow^* 0011$
- $S \Rightarrow^{(1)} 0S1$ et $0S1 \Rightarrow^{(1)} 00S11$
donc $S \Rightarrow^* 00S11$ ou $S \Rightarrow^{(2)} 00S11$
- $S \Rightarrow^* 000111$ car
 $S \Rightarrow^{(1)} 0S1 \Rightarrow^{(1)} 00S11 \Rightarrow^{(1)} 000111$

Remarque : $000111 = 0^31^3 \neq (01)^3 = 010101$

GRAMMAIRE

Définition (Langage)

Le langage engendré par une grammaire $\mathbf{G}=(\mathbf{T},\mathbf{N},\mathbf{S},\mathbf{P})$, noté $\mathbf{L(G)}$ est exactement l'ensemble des mots appartenant à T^* générés (directement ou indirectement) à partir de l'axiome.

$$L(G)=\{w / S \Rightarrow^* w \text{ et } w \in T^*\} \text{ ou } L(G)=\{w / S \Rightarrow^* w\} \cap T^*$$

Le langage généré par G contient exactement :

- les mots dérivables à partir de l'axiome
- ne contenant que des symboles terminaux.

GRAMMAIRE

Exemple : Soit $G = (\{a, b\}, \{S\}, S, \{S \rightarrow aSb / ab\})$

On distingue deux types de règles :

- **Une règle récursive :** $S \rightarrow aSb$

Le non-terminal S apparaît dans le membre gauche ainsi que dans le membre droit.

Cette règle va être utilisée de manière récursive comme suit :

$$S \Rightarrow aSb \Rightarrow aaSbb \Rightarrow aaaSbbb \Rightarrow \dots \Rightarrow a^n S b^n$$

Donc, $S \Rightarrow^* a^n S b^n$ avec $n \geq 0$

Notons que le mot obtenu n'est pas un mot du langage généré par la grammaire car il contient un non-terminal.

- **Une règle d'arrêt :** $S \rightarrow ab$

Il n'y a pas de non-terminal S dans le membre droit. Dans ce cas précis, il n'y a que des terminaux dans le membre droit.

GRAMMAIRE

On peut utiliser la règle d'arrêt à tout moment, donc :

$$S \Rightarrow^* a^n S b^n \Rightarrow a^n a b b^n = a^{n+1} b^{n+1} \text{ avec } n \geq 0$$

Donc, **$S \Rightarrow^* a^{n+1} b^{n+1}$** avec $n \geq 0$

Dans ce cas, le mot obtenu **ne contient que des terminaux** et donc c'est un mot du langage généré par la grammaire.

Il n'y a pas d'autres dérivations possibles, donc :

$$\begin{aligned} L(G) &= \{a^{n+1} b^{n+1} / n \geq 0\} \\ &= \{a^n b^n / n \geq 1\} \end{aligned}$$

GRAMMAIRE

Définition (Grammaires équivalentes)

Deux grammaires G_1 et G_2 sont dites équivalentes, notées $G_1 \equiv G_2$, si elles engendrent (génèrent) le même langage.

$$G_1 \equiv G_2 \Leftrightarrow L(G_1) = L(G_2)$$

Exemple :

Montrer que les deux grammaires G_1 et G_2 sont équivalentes:

$$G_1 = (\{a, b\}, \{S, A, B\}, S, \{S \rightarrow AB, A \rightarrow aA/\varepsilon, B \rightarrow bB/\varepsilon\})$$

$$G_2 = (\{a, b\}, \{S, B\}, S, \{S \rightarrow aS/B, B \rightarrow bB/\varepsilon\})$$

Dans G_1 : $S \rightarrow AB$ et $A \rightarrow aA \rightarrow aaA \rightarrow aaaA \dots$ donc $A \Rightarrow^* a^n$ (pareil: $B \Rightarrow^* b^m$)

$$\text{Donc } L(G_1) = \{a^n b^m / n \geq 0 \text{ et } m \geq 0\}$$

Dans G_2 : $S \rightarrow aS \rightarrow aaS \rightarrow \dots \rightarrow a^n S \rightarrow a^n B \rightarrow a^n bB \rightarrow a^n bbB \rightarrow \dots \rightarrow a^n b^m B \rightarrow a^n b^m$

$$\text{Donc } L(G_2) = \{a^n b^m / n \geq 0 \text{ et } m \geq 0\}$$

Ces deux grammaires génèrent le même langage : $\{a^n b^m / n \geq 0 \text{ et } m \geq 0\}$

Remarque : Un langage peut être généré par plusieurs grammaires, mais une grammaire ne génère qu'un seul langage.

CLASSIFICATION DES GRAMMAIRES

Noam Chomsky a décomposé les grammaires formelles en catégories de pouvoir d'expression croissant, c'est-à-dire en groupes successifs pouvant chacun générer une variété de langages plus large que le groupe précédent.

On parle de **Hiérarchie (Classification) de Chomsky**.

Chomsky a défini **quatre types** de grammaires formelles suivant la nature des règles de production des grammaires.

Type 3 (Grammaires régulières) : Une grammaire $G=(T, N, S, P)$ est de type 3 ssi elle est soit régulière **droite** soit régulière **gauche**.

□ **Grammaire régulière droite** :

Si toutes les productions dans P sont de la forme :

$A \rightarrow wB$ ou $A \rightarrow w$ avec $A, B \in N$ et $w \in T^*$

Exemples : $A \rightarrow aabB$ $A \rightarrow B$ $A \rightarrow aa$ $A \rightarrow \varepsilon$: sont de type 3 (RD) 27

$A \rightarrow aBB$ $A \rightarrow aBa$ $A \rightarrow AB$: ne sont pas de type 3

CLASSIFICATION DES GRAMMAIRES

□ Grammaire régulière gauche :

Si toutes les productions dans P sont de la forme :

$$A \rightarrow Bw \text{ ou } A \rightarrow w \quad \text{avec} \quad A, B \in N \text{ et } w \in T^*$$

Exemples : $A \rightarrow Baab$ $A \rightarrow B$ $A \rightarrow aa$ $A \rightarrow \varepsilon$: sont de type 3 (RG)

Remarques :

- Les trois dernières règles sont droites et gauches en même temps.
- Une grammaire de type 3 ne doit pas contenir en même temps :
 - des règles régulières droites ($A \rightarrow wB$) et
 - des règles régulières gauches ($A \rightarrow Bw$).

(Pour qu'une grammaire soit régulière : il faut que toutes ses règles soient régulières droites **ou** toutes régulières gauches)

CLASSIFICATION DES GRAMMAIRES

Type 2 (Grammaires algébriques ou grammaires à contexte libre)

Une grammaire $G=(T, N, S, P)$ est de type 2 si et seulement si toutes les productions de P sont de la forme :

$$A \rightarrow \alpha \quad \text{avec } A \in N \text{ et } \alpha \in (T \cup N)^*$$

Exemples : $A \rightarrow aBb$ $A \rightarrow aBBa$ $A \rightarrow BB$ $A \rightarrow Bab$ $A \rightarrow abB$ $A \rightarrow \varepsilon$

sont de type 2 (algébriques)

Remarque :

La seule condition porte sur le membre gauche qui est constitué d'un seul non-terminal.

CLASSIFICATION DES GRAMMAIRES

Type 1 (Grammaires Contextuelles)

Une grammaire $G=(T, N, S, P)$ est de type 1 si et seulement si toutes les règles de production de P sont de la forme :

$$\alpha A \beta \rightarrow \alpha w \beta \text{ avec } \alpha, \beta \in (T \cup N)^*, A \in N, w \in (T \cup N)^+$$

et une contrainte sur le mot vide : **seul l'axiome peut générer le mot vide** et dans ce cas il n'apparaît dans aucun membre droit d'une règle de production.

La règle $\alpha A \beta \rightarrow \alpha w \beta$ signifie que le non terminal A est remplacé par w si son contexte gauche est α et son contexte droit est β .

Exemples : $aAb \rightarrow aBBb$ $aA \rightarrow aBBa$ $Ab \rightarrow BBb$ $A \rightarrow AB/a$ sont de type 1

Remarque : Les grammaires contextuelles sont appelées aussi grammaires à contexte lié.

CLASSIFICATION DES GRAMMAIRES

Type 0 (Grammaire sans restriction ou Grammaire Générale)

Une grammaire $G=(T, N, S, P)$ est de type 0 si la forme des règles de production dans P n'est l'objet d'aucune restriction

Donc, Type 3 : $A \rightarrow wB$ (ou $A \rightarrow Bw$) et $A \rightarrow w$ $A \in N$ et $w \in T^*$

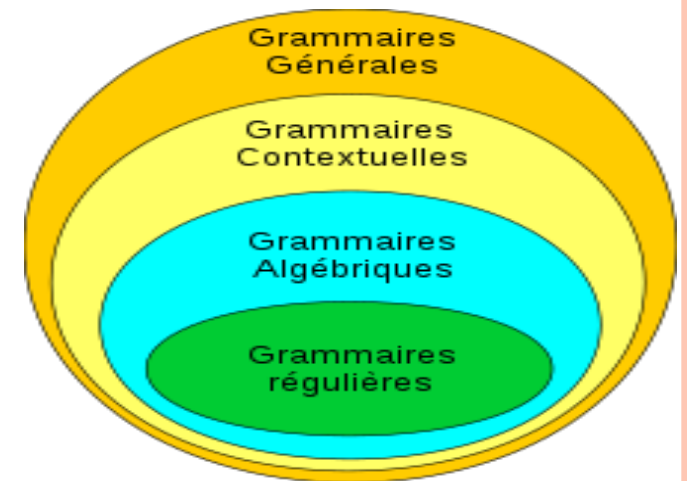
Type 2 : $A \rightarrow w$ $A \in N$ et $w \in (T \cup N)^*$

Type 1 : $\alpha A \beta \rightarrow \alpha w \beta$

Type 0 : aucune contrainte

Ainsi, nous avons la hiérarchie de Shomsky :

type 3 \subseteq type 2 \subseteq type 1 \subseteq type 0



Remarque : Pour une grammaire G donnée, on cherche à trouver le **plus petit type** de G au sens de l'inclusion (du plus haut rang)

CLASSIFICATION DES GRAMMAIRES

Exemple : Soit une grammaire $G=(\{a, b\}, \{S, A\}, S, P)$ où:

$$P=\{ S \rightarrow aaS / A, \quad A \rightarrow bbA / bb \}.$$

G est une grammaire de **type 2** car toutes les règles sont de la forme :

$$A \rightarrow \alpha \quad \text{avec } A \in N \text{ et } \alpha \in (T \cup N)^*$$

Mais elle est aussi de **type 3** (régulière droite) car toutes les règles sont de la forme : $A \rightarrow wB$ ou $A \rightarrow w$ avec $A, B \in N$ et $w \in T^*$

Dans ce cas, on dira qu'elle est de type 3.

C'est le plus petit type au sens de l'inclusion.

Etant donnée une grammaire G, on vérifie dans l'ordre :

Si elle est de type 3

Sinon si elle est de type 2

Sinon si elle est de type 1

Sinon elle est de type 0.

CLASSIFICATION DES LANGAGES

A chaque type de grammaire est associé un type de langage :

- Les grammaires de **type 3** génèrent les langages **réguliers**.
- Les grammaires de **type 2** génèrent les langages **algébriques** ou à **contexte libre**
- Les grammaires de **type 1** génèrent les langages **contextuels** ou à **contexte lié**
- Les grammaires de **type 0** génèrent tous les langages **récurivement énumérables**.

CLASSIFICATION DES LANGAGES

Définition (Type d'un langage)

Un langage est **de type i** s'il existe une **grammaire de type i** qui le **génère** (engendre) .

Un langage est **strictement de type i** :

- s'il est engendré par une **grammaire de type i**
- et il **n'existe pas** de grammaire de **type supérieur à i** qui l'engendre.

Exemple: $\{a^n b^m / n, m \geq 0\}$ est de type 3 mais $\{a^n b^n / n \geq 0\}$ est strictement de type 2

Remarques :

- ❑ Un langage peut être généré par différentes grammaires qui peuvent être de type différent.
- ❑ Un langage **prend le plus petit type au sens de l'inclusion**.

CLASSIFICATION DES LANGAGES

Exemple : Soit le langage $L_1 = \{ ww^R / w \in \{a, b\}^* \}$

$L_1 = \{ \varepsilon, aa, bb, abba, aaaa, bbbb, abbbba, abaaba, \dots \}$

L_1 est généré par la grammaire $G_1 = (\{a, b\}, \{S\}, S, P)$ où:
 $P = \{ S \rightarrow aSa / bSb / \varepsilon \}.$

G n'est pas de type 3 car la règle $S \rightarrow aSa$ n'est ni régulière droite ni régulière gauche.

Cette grammaire est de type 2 car toutes les règles sont de la forme :
 $A \rightarrow \alpha$ avec $A \in N$ et $\alpha \in (T \cup N)^*$.

Donc L_1 est de type 2 car il est généré par une grammaire de type 2.

CLASSIFICATION DES LANGAGES

Exemple : Soit le langage $L_2 = \{a^{2^n}b^m \mid n, m \geq 0\}$

$L_2 = \{\varepsilon, aa, b, aab, aaaa, bbb, aabbbb, aaaabbbbbbbb, \dots\}$

L_2 est généré par la grammaire $G_2 = (\{a, b\}, \{S, A, B\}, S, P)$ où

$$P = \{S \rightarrow AB, A \rightarrow aaA/\varepsilon, B \rightarrow bB/\varepsilon\}$$

G_2 n'est pas de type 3 car la règle $S \rightarrow AB$ n'est ni régulière droite ni régulière gauche.

Par contre, G_2 est de type 2 car toutes les règles sont de la forme

$$A \rightarrow \alpha \text{ avec } A \in N \text{ et } \alpha \in (T \cup N)^*.$$

L_2 est donc de type 2 car il est généré par G_2 qui est de type 2.

Peut-on trouver une grammaire de type 3 qui le génère ?

CLASSIFICATION DES LANGAGES

Toujours pour le langage $L_2 = \{a^{2^n}b^m \mid n, m \geq 0\}$

$L_2 = \{\epsilon, aa, b, aab, aaaa, bbb, aabbbb, aaaabbbbbbbb, \dots\}$

Soit la grammaire $G_3 = (\{a, b\}, \{S, B\}, S, P)$ où

$P = \{S \rightarrow aaS \mid B, B \rightarrow bB \mid \epsilon\}$.

G_3 est une grammaire de type 3. En effet, elle est régulière droite. Toutes les règles sont de la forme :

$A \rightarrow wB$ ou $A \rightarrow w$ avec $A, B \in N$ et $w \in T^*$.

La grammaire G_3 génère le langage L_2 .

Donc, L_2 est de type 3. C'est le plus petit type au sens de l'inclusion.

Etant donné un langage L , on cherche toujours à déterminer le type le plus petit au sens de l'inclusion.

EXEMPLES CLASSIQUES DE LANGAGES

Type 3 : $L = \{ a^n b^m / n, m \geq 0 \}.$

$L = \{ \varepsilon, a, b, aa, bbb, aaabb, abbb, \dots, a---ab-----b, \dots \}$

Une grammaire de type 3 qui engendre L est :

$G = (\{a,b\}, \{S,B\}, S, \{S \rightarrow aS / B ; B \rightarrow bB / \varepsilon \}.$

Type 2 : $L = \{ a^n b^n / n \geq 0 \}$

$L = \{ \varepsilon, ab, aabb, aaabbb, aaaabbbb, \dots, a---ab---b, \dots \}$

Une grammaire de type 2 qui engendre L est :

$G = (\{a,b\}, \{S\}, S, \{S \rightarrow aSb / \varepsilon \}$

LANGAGES ET AUTOMATES

Enfin, à **chaque type de langage** est associé un **type d'automate** qui permet de reconnaître les langages de sa classe :

- Les langages de **Type 3** appelés aussi **langages réguliers** sont reconnus par des **automates d'états finis**.
- Les langages de **Type 2** appelés aussi **langages algébriques** sont reconnus par des **automates à piles**.
- Les langages de **Type 1** appelés aussi **langages contextuels** sont reconnus par des **automates à bornes linéaires**.
- Les langages de **Type 0** appelés aussi **langages récursivement énumérables** sont reconnus par des **machines de Turing**.