

Chapitre 0. Introduction

Définitions

- Alphabet
- Mot
- Langage

Définitions

Alphabet :

- Un alphabet (ou vocabulaire) est un ensemble fini non vide de symboles (ou caractères ou lettres).
On le notera en général Σ , dans la suite du cours

Exemples :

$$\Sigma_1 = \{ \bullet, \clubsuit, \diamond \}$$

$$\Sigma_2 = \{ a, b, c, \dots, z \}$$

$$\Sigma_3 = \{ \text{if, then, else, id, nb, =, +} \}$$

Mot :

- Un mot, défini sur un alphabet Σ , est une suite (ou séquence) finie d'éléments de Σ

Exemples :

- sur l'alphabet Σ_1 , les mots \clubsuit , $\diamond \clubsuit$, $\diamond \clubsuit \bullet$
- sur l'alphabet Σ_2 , les mots programme, et, if, aba, sbl, cad, ple, ...
- sur l'alphabet Σ_3 , les mots if id = nb, idif, else, ...

Remarque : les caractères a, b, c, ..., z (en minuscule) seront utilisés pour designer un mot

Longueur d'un mot :

- La longueur d'un mot f défini sur un alphabet Σ , notée $|f|$, est le nombre de symboles qui composent f .

Chapitre 0. Introduction

Par exemple :

- Sur Σ_1 le mot $f = \spadesuit \clubsuit \heartsuit$, $|f| = 3$
- Sur Σ_2 le mot $f = if$, $|f| = 2$
- Sur Σ_3 le mot $f = ifid = nb$, $|f| = 4$

Mot vide :

- le mot vide, noté λ ou ε , est défini sur tous les alphabets et est le mot de longueur 0 ($|\varepsilon| = 0$).

Les ensembles Σ^+ et Σ^* :

- On note Σ^+ l'ensemble des mots de longueur supérieure ou égale à 1 que l'on peut construire à partir de l'alphabet Σ
- On note Σ^* l'ensemble des mots que l'on peut construire à partir de Σ , y compris le mot vide :

$$\Sigma^* = \Sigma^+ \cup \{\varepsilon\}$$

Chapitre 0. Introduction

Par exemple :

- Soit $\Sigma = \{a, b\}$ un alphabet,

➤ Σ^+ comprend :

- Longueur 1: **a, b**
- Longueur 2 : **aa, ab, ba, bb**
- Longueur 3 : **aaa, aab, aba, abb, baa, bba, bab, bbb**
-

➤ Σ^* comprend :

$$\Sigma^+ \cup \{\text{mot de longueur } 0 : \varepsilon\}$$

Opérations sur les mots

1°) Concaténation

- Soient deux mots f et g définis sur un alphabet Σ . La concaténation de f avec g , notée $f.g$ (ou fg) est le mot formé en faisant suivre les symboles de f par les symboles de g .
- La puissance d'un mot f , notée f^n est la concaténation du mot f n fois. Cette puissance est calculée de manière itérative comme suit :

$$\left\{ \begin{array}{l} f^0 = \varepsilon, \\ f^n = f.f^{n-1} \text{ pour } n \geq 1 \end{array} \right.$$

Exemple :

Sur l'alphabet Σ_2 si $u = ab$ et $v = cd$ alors $u.v = abcd$, $v.u = cdab$ et $u^3 = ababab$

Propriétés

- La concaténation est associative mais non commutative.
- La concaténation est une loi de composition interne de Σ
- Et ε est son élément neutre. Par conséquent, $(\Sigma^*, .)$ est un monoïde

2°) Préfixe, Suffixe et Facteur

- Soient deux mots f et g définis sur un alphabet Σ :
 - f est un préfixe (ou facteur gauche) de g si et seulement si $\exists h \in \Sigma^*$ tel que $g = fh$
 - f est un suffixe (ou facteur droit) de g si et seulement si $\exists h \in \Sigma^*$ tel que $g = hf$
 - f est un facteur de g si et seulement si $\exists h_1 \text{ et } h_2 \in \Sigma^*$ tel que $g = h_1fh_2$

Remarque :

Si $f \neq g$ et $f \neq \varepsilon$ alors f est dit facteur propre de g

Le mot vide est préfixe, suffixe de tout mot

3°) Sous-mot

- Soient f et g deux mots $\in \Sigma^*$, f est un sous-mot de g s'il existe $h_1, h_2, \dots, h_{n+1} \in \Sigma^*$ tels que :

$$f = f_1 f_2 \dots f_n, \forall i \ 1 \leq i \leq n \ f_i \in \Sigma \text{ et } g = h_1 f_1 h_2 f_2 \dots f_n h_{n+1}$$

Remarque :

- Un facteur est un sous-mot mais l'inverse n'est pas vrai.

Exemple :

Soit $\Sigma = \{a, b, c\}$ un alphabet et $f \in \Sigma^*$ tel que $f = ababc$

$f = u \cdot x \cdot v \mid u \in \text{préfixes}(f), x \in \text{sous-chaînes}(f) \text{ et } v \in \text{suffixes}(f)$

- $\text{préfixes}(f) = \{ u \mid f = u \cdot v \} = \{ \lambda, a, ab, aba, abab, ababc \}$
- $\text{suffixes}(f) = \{ v \mid f = u \cdot v \} = \{ \lambda, c, bc, abc, babc, ababc \}$
- $\text{sous-mot}(f) = \{ \lambda, a, b, c, ab, ba, bc, aba, bab, abc, abab, babc, ababc \}$

4°) Mots conjugués

Soient f et g deux mots de Σ^* , f et g sont conjugués s'il existe u et v deux mots $\in \Sigma^*$ tel que

$$f = uv \text{ et } g = vu$$

5°) Miroir d'un mot

Soit f un mot de Σ^* , l'image miroir de $f = a_1 a_2 \dots a_n$ où $a_i \in \Sigma \forall i, 1 \leq i \leq n$ est définie par

$$f^R = a_n a_{n-1} \dots a_1$$

Un mot est un palindrome s'il est égal à son miroir

Exemple :

$$\Sigma = \{a, b\}, f = aba \text{ et } f^R = aba$$

Langage

- Un langage, défini sur un alphabet Σ , est un ensemble de mots définis sur Σ . C'est donc un sous-ensemble de Σ^*

Deux langages particuliers sont indépendants de l'alphabet Σ :

- le langage vide ($L = \emptyset$),
- le langage contenant le seul mot vide ($L = \{\varepsilon\}$)

Opérations ensemblistes sur les langages :

Soient 2 langages $L1$ sur $\Sigma1$ et $L2$ sur $\Sigma2$:

- L'union de $L1$ et de $L2$, notée $L1 \cup L2$, est le langage défini sur $\Sigma1 \cup \Sigma2$ par l'ensemble de tous les mots contenus soit dans $L1$ ou dans $L2$

$$L1 \cup L2 = \{f / f \in L1 \text{ ou } f \in L2\}$$

- L'intersection de $L1$ et de $L2$ est le langage défini sur $\Sigma1 \cap \Sigma2$ par

$$L1 \cap L2 = \{f / f \in L1 \text{ et } f \in L2\}$$

- Le complémentaire de $L1$ est le langage défini sur $\Sigma1$ par :

$$C(L1) = \{f \in \Sigma1^* \text{ et } f \notin L1\}$$

- La différence de $L1$ et de $L2$ est le langage défini sur $\Sigma1$ par :

$$L1 - L2 = \{f / f \in L1 \text{ et } f \notin L2\}$$

Opérations définies sur les langages :

Soient 2 langages L_1 sur Σ_1 et L_2 sur Σ_2 :

- **Le produit** ou concaténation de L_1 et de L_2 , est le langage défini sur $\Sigma_1 \cup \Sigma_2$ par :

$$L_1.L_2 = \{fg / f \in L_1 \text{ et } g \in L_2\}$$

Remarque :

Le produit de langages est associatif mais non commutatif

- **La puissance** d'un langage L est définie de manière récursive par :

$$L^0 = \{\varepsilon\}$$

$$L^n = L.L^{n-1} \text{ pour } n \geq 1$$

- **La fermeture itérative** (ou de Kleene) d'un langage L , notée L^* est définie par :

$$L^* = \cup_{i=0}^{\infty} L^i$$

De même, on définit L^+ par :

$$L^+ = \cup_{i=1}^{\infty} L^i$$

Exemple :

$\Sigma = \{a, b\}$, $L = \{a.b\}$, Calculer L^*

Remarque :

- Un langage fini peut être décrit par l'énumération des mots qui le composent.
- Certains langages infinis peuvent être décrits par l'application d'opérations sur des langages plus simples.
- Certains langages infinis peuvent être décrits par un ensemble de règles appelé grammaire.

Système de génération des langages : Les Grammaires

Définition :

Une grammaire formelle est un quadruplet $G = (N, \Sigma, P, S)$ où :

- N est l'alphabet non terminal ou ensemble des symboles non-terminaux. Ces symboles sont utilisés dans le processus de génération mais n'apparaissent pas dans les mots générés,
- Σ est l'alphabet terminal, l'alphabet sur lequel est défini le langage
- $S \in N$, est le symbole de départ ou axiome
- P est l'ensemble des règles de production de la forme :

$$\alpha \rightarrow \beta \text{ avec } \alpha \in (N \cup \Sigma)^+ \\ \text{et } \beta \in (N \cup \Sigma)^*$$

Langage généré par une grammaire :

Soit $G = (N, \Sigma, P, S)$ une grammaire, le langage généré par G , noté $L(G)$ est défini par :

$$L(G) = \{f \in \Sigma^* / S \text{ dérive } f \text{ après plusieurs étapes}\}$$

Remarque :

- Une grammaire définit un seul langage
- Un même langage peut être généré par plusieurs grammaires différentes

Exercice :

1°) Soit $G = (N, \Sigma, P, S)$ avec $N = \{S\}$, $\Sigma = \{b, c\}$ et $P = \{S \rightarrow bS \mid cc\}$

Déterminer $L(G)$

2°) Construire une grammaire qui génère $L = \{ba^n b \mid n \geq 0\}$

Classification de Chomsky

En introduisant des restrictions sur la forme des règles de production, on obtient différentes classes de grammaire, ordonnées par inclusion. On distingue les 4 types suivants :

- **Type 0** : pas de restriction sur les règles.
- **Type 1** : grammaires dépendantes du contexte ou contextuelles. Les règles de P sont de la forme :

$$\alpha A \beta \rightarrow \alpha \gamma \beta \text{ avec } A \in N, \alpha \text{ et } \beta \in (N \cup \Sigma)^* \text{ et } \gamma \in (N \cup \Sigma)^+$$

Autrement dit que le symbole non-terminal A est remplacé par γ si on a les contextes α à gauche et β à droite.

- **Type 2** : grammaires algébriques ou hors-contexte. Les règles de P sont de la forme :

$$A \rightarrow \alpha \text{ avec } A \in N \text{ et } \alpha \in (N \cup \Sigma)^*$$

- **Type 3** : grammaires régulières

– à droite. Les règles de P sont de la forme : $A \rightarrow fB / f$ avec $f \in \Sigma^*$ et A et B $\in N$

– à gauche. Les règles de R sont de la forme : $A \rightarrow Bf / f$ avec $f \in \Sigma^*$ et A et B $\in N$

Chapitre 0. Introduction

A chaque type de grammaire est associé un type de langage :

- les grammaires de **type 3** génèrent les langages **réguliers**,
- les grammaires de **type 2** génèrent les langages **algébriques**,
- les grammaires de **type 1** génèrent les langages **contextuels**,
- les grammaires de **type 0** permettent de générer tous les langages “**décidables**”, autrement dit, tous les langages qui peuvent être reconnus en un temps fini par une machine. Les langages qui ne peuvent pas être générés par une grammaire de type 0 sont dits “indécidables”.

Ces langages sont ordonnés par inclusion :

$$\mathbf{T3 \subset T2 \subset T1 \subset T0}$$

Chapitre 0. Introduction

A chaque type de grammaire est associé un type d'automate qui permet de reconnaître les langages de sa classe :

- Les langages **réguliers** sont reconnus par des **automates finis**,
- Les langages **algébriques** sont reconnus par des **automates à pile**
- Les autres langages, décrits par des grammaires de **type 1 ou 0**, sont reconnus par des **machines de Turing**.